# 第 5 章: 発見

今井耕介 著

『社会科学のためのデータ分析入門 (QSS)』

2026-03-09

# 5.1 テキストデータ

# Federalist Papers の分析

- テキストマイニングを用いて、著者不明のエッセイの執筆者を推定する。

```
library(tm)
# コーパスの読み込み
corpus.raw <- VCorpus(DirSource(directory = "federalist", pattern = "fp"))
# 前処理（小文字化、空白削除、句読点削除、ストップワード削除、ステミング）
corpus <- tm_map(corpus.raw, content_transformer(tolower))
corpus <- tm_map(corpus, stripWhitespace)
corpus <- tm_map(corpus, removePunctuation)
corpus <- tm_map(corpus, removeNumbers)
corpus <- tm_map(corpus, removeWords, stopwords("english"))
corpus <- tm_map(corpus, stemDocument)
```

# ワードクラウド (Word Cloud)

- 出現頻度の高い単語を視覚化する。

```
library(wordcloud)
dtm <- DocumentTermMatrix(corpus)
dtm.mat <- as.matrix(dtm)
# 第 10 論文のワードクラウド
wordcloud(colnames(dtm.mat), dtm.mat[10, ], max.words = 20)
```

# 5.2 ネットワークデータ

# ルネサンス期フィレンツェの婚姻関係

- どの家族が中心的な役割を果たしていたかをネットワーク指標で測る。

```
library(igraph)
florence <- read.csv("florentine.csv", row.names = "FAMILY")
# 隣接行列からグラフオブジェクトを作成
g <- graph_from_adjacency_matrix(as.matrix(florence), mode = "undirected")
# 次数中心性 (Degree Centrality)
sort(degree(g), decreasing = TRUE)[1:3]
```

```
##   MEDICI GUADAGNI  STROZZI
##        6        4        4
```

# ネットワークの可視化

```
# 間中心性 (Betweenness Centrality) に基づくノードサイズ
plot(g, vertex.size = betweenness(g) * 0.5,
     main = "Betweenness Centrality in Florence")
```

# 5.3 地理空間データ

# ウォルマートの拡大 (1)

- 店舗の緯度・経度データを用いて、全米への拡大プロセスを可視化する。

```
library(maps)
walmart <- read.csv("walmart.csv")
# データ構造の確認
head(walmart, n = 3)
```

```
##     opendate                     st.address        city state      long
## 1 1962-03-01 5801 SW Regional Airport Blvd Bentonville    AR -
94.23982 36.35088
## 2 1962-07-01              2110 WEST WALNUT      Rogers    AR -
94.07141 36.34224
## 3 1964-08-01              1417 HWY 62/65 N    Harrison    AR -
93.09345 36.23698
##                 type
## 1 DistributionCenter
## 2        SuperCenter
## 3        SuperCenter
```

```r
# 地図の描画とプロット
map(database = "state")
points(walmart$long, walmart$lat, pch = 19, cex = 0.2,
       col = rgb(0, 0, 1, alpha = 0.1))
title("Expansion of Walmart")
```

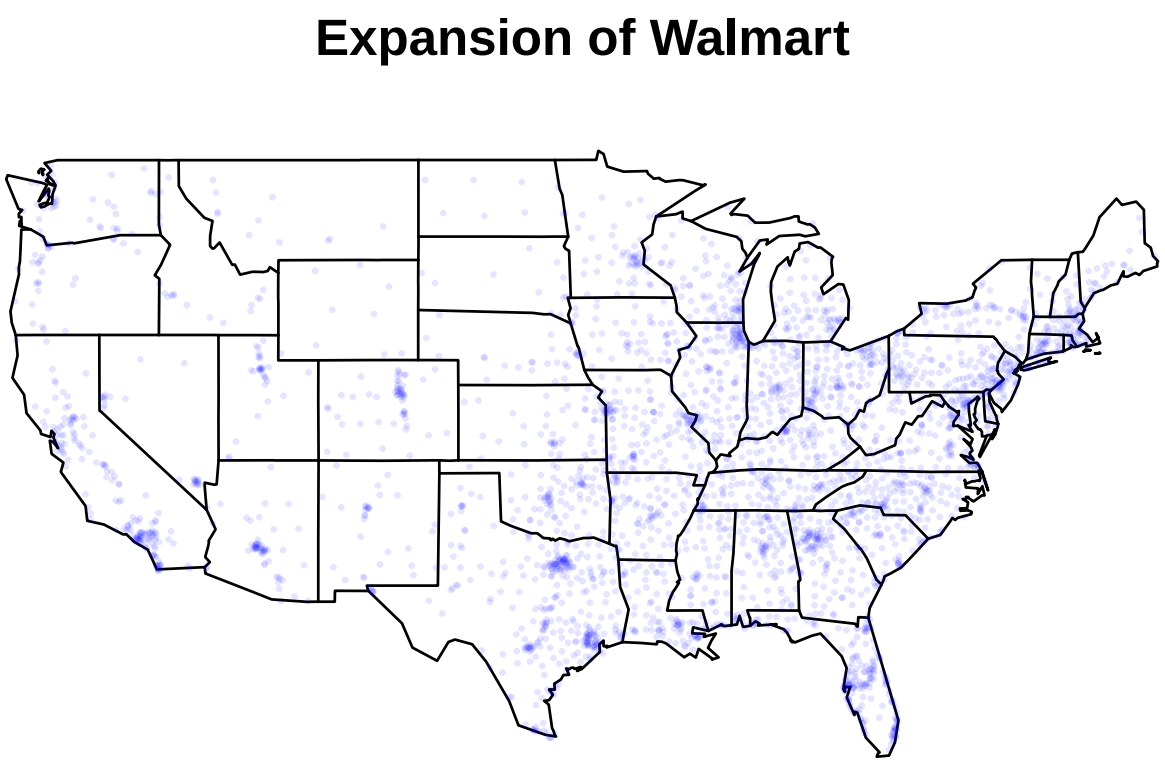

# 大統領選挙のマップ

- 2008 年選挙の結果を州ごとに色分けする。

```
pres08 <- read.csv("pres08.csv")
pres08$margin <- pres08$Obama - pres08$McCain
# 最初の数件を確認
head(pres08[, c("state", "margin")], n = 3)
```

```
##   state margin
## 1    AL    -21
## 2    AK    -21
## 3    AZ     -9
```

```
map(database = "state")
for (i in 1:nrow(pres08)) {
  if (!(pres08$state[i] %in% c("AK", "HI", "DC"))) {
    map(database = "state", regions = pres08$state.name[i],
        col = ifelse(pres08$margin[i] > 0, "blue", "red"),
        fill = TRUE, add = TRUE)
  }
}
```

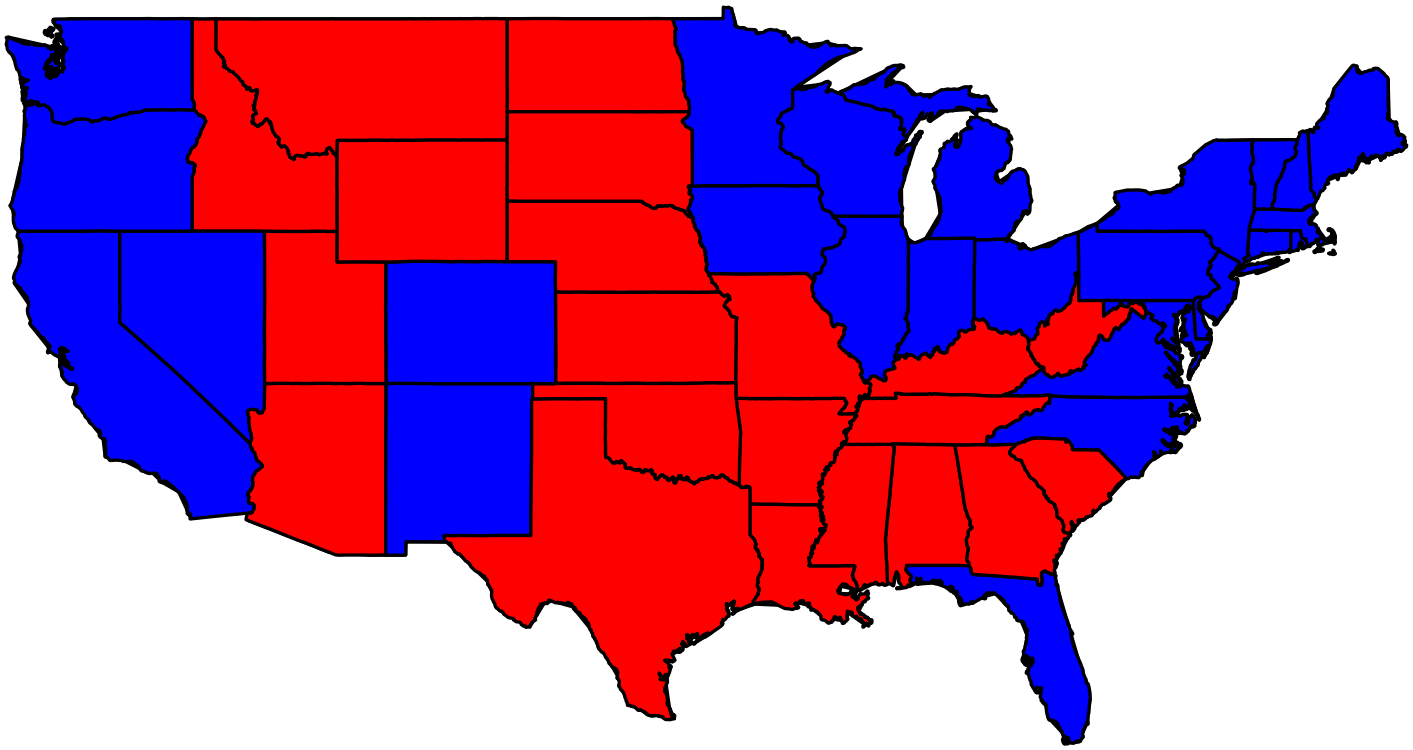

# 5.4 まとめ

# 第5章のまとめ

- **テキスト分析**: 非構造的な文書データから、著者の特徴やトピック（話題）を抽出する。
- **ネットワーク分析**: 要素間のつながり（エッジ）と結節点（ノード）を分析し、中心性を測定する。
- **空間分析**: 緯度・経度情報を利用して、現象の地理的な広がりを視覚化する。
- R の操作: `tm`, `igraph`, `maps` パッケージ、`rgb()` による透過色の設定、`for` ループによる地図の着色。